

Modelo de predicción de fuga y segmentación de clientes

Prueba técnica — Especialista en Ciencia de Datos

Fundación Génesis Empresarial

Julio Vicente

joulefvicente@gmail.com

El modelo captura el 62 % de las fugas contactando al 20 % de la cartera. La probabilidad entregada está calibrada: en el decil de mayor riesgo predice 93 % y se retira el 92 %.

18 de agosto de 2026

Mapa de respuestas

Ubicación de la respuesta a cada inciso del enunciado:

Inciso	Requerimiento	Sección
1.a	Algoritmos utilizados en el modelo de fuga	§3.1
1.b	Algoritmo de la probabilidad y justificación	§3.2
1.c	Variables de mayor impacto	§3.4
1.d	% de probabilidad de fuga por cliente	§4.2 + XLSX
1.e	Clientes recomendados para campaña	§4.3 + XLSX
1.f	Segmentación, dashboard y patrones	§5 y §7
2.a	Reglas de asociación	§6.1
2.b	Justificación de las reglas elegidas	§6.2
2.c	Uso recomendado de los resultados	§6.3
3	Tablero de visualización	§7

Archivos que acompañan a este informe:

- Genesis_Churn_Prediccion_Julio_Vicente.xlsx — los 10 000 clientes con su probabilidad, decil, segmento y recomendación de campaña (incisos 1.d y 1.e).
- Genesis_Segmentacion_Julio_Vicente.xlsx — perfiles de segmento y asignación por cliente (inciso 1.f).
- Genesis_Reglas_Asociacion_Julio_Vicente.xlsx — reglas de asociación (inciso 2).
- Genesis_Auditoria_Datos_Julio_Vicente.xlsx — evidencia de la auditoría de datos.
- Tablero_Cartera_Riesgo_Julio_Vicente.html — tablero interactivo de cinco páginas, autónomo (inciso 3). Descrito en §7.

El detalle por cliente no se imprime en este documento: aquí van los resultados agregados y la justificación metodológica.

Índice

Mapa de respuestas	1
1. Resumen ejecutivo	3
2. Datos, auditoría y validación	4
2.1. Las tres bases	4
2.2. Auditoría de variables	4
2.3. Esquema de validación	5
3. Modelo de predicción de fuga	6
3.1. Algoritmos evaluados	6
3.2. Modelo seleccionado y calibración de probabilidades	7
3.3. Desempeño	7
3.4. Variables de mayor impacto	8
4. Aplicación a los clientes activos	10
4.1. Tratamiento del segmento de primer crédito	10
4.2. Distribución de probabilidades de fuga	10
4.3. Selección de clientes para campaña de retención	11
5. Segmentación de clientes	13
5.1. Metodología y selección de k	13
5.2. Perfil de cada segmento	14
5.3. Cruce entre segmento y riesgo de fuga	16
5.4. Patrones encontrados	16
6. Reglas de asociación — base Bakery	16
6.1. Reglas encontradas	16
6.2. Criterio de selección de las reglas	18
6.3. Uso recomendado de los resultados	19
7. Tablero de visualización	20
8. Limitaciones y siguientes pasos	20
A. Evidencia de la auditoría de datos	22
B. Reproducibilidad	23

1 Resumen ejecutivo

De los 10 000 clientes activos, el modelo espera que se retiren **3 442** (34.4 % de la cartera). Ese riesgo no está repartido de forma pareja: se concentra, y esa concentración es lo que hace accionable el modelo.

Los tres números que importan

1. **Contactando al 20 % de los clientes de mayor riesgo se alcanza al 62 % de quienes se van a retirar.** Al 30 %, se alcanza al 82 %. El decil más riesgoso concentra 3.51 veces más fugas que un grupo elegido al azar.
2. **La probabilidad entregada es una probabilidad real, no un puntaje.** En el conjunto de prueba, el decil superior tiene una probabilidad media predicha de 93.3 % y una tasa observada de 92.2 %. La correspondencia se mantiene decil a decil (tabla 3).
3. **Se recomienda contactar a 4 957 clientes** bajo el supuesto base de 20 % de efectividad de campaña, con un retorno esperado de 3.6 veces el costo. Si el área comercial sólo puede atender 1 000 contactos, la lista priorizada por valor esperado captura el 24 % de todas las fugas.

De qué datos salen estos números

Se trabajó sobre tres bases: **78 829 clientes históricos** con desenlace conocido — una fila por cliente, no un panel cliente–mes —, los **10 000 clientes activos** a los que se aplica el modelo y **9 981 tickets** de la panadería para el ejercicio de canastas. Se considera *fugado* al cliente cuyo registro figura como *Cliente Retirado*: cerró su ciclo de crédito sin renovar dentro de la ventana de 30 meses. La prevalencia histórica es de 38.1 %, un desbalance moderado que no exige remuestreo sintético.

Tres condiciones de los datos determinaron el diseño del trabajo, y conviene enunciarlas antes que cualquier resultado:

1. **La base histórica contiene dos variables que revelan la respuesta.** El código de cliente separa retirados y renovados con exactitud perfecta, porque el archivo fue ordenado por estado antes de numerarse; y estar en el primer crédito implica ser retirado por definición lógica, no por comportamiento. Un modelo que las use reporta métricas impecables en entrenamiento y produce ruido sobre los 10 000 activos, cuyos códigos fueron reenumerados. Ambas se descartaron, y el segmento de primer crédito se modela aparte.
2. **No hay fechas ni comportamiento de pago.** Ninguna base registra desembolso, vencimiento, mora ni puntualidad de cuotas. Eso impide una validación fuera de tiempo y descarta las variables de tendencia, que en cartera de microcrédito suelen ser las más predictivas: el desempeño reportado es un piso y no un techo.
3. **Los montos no son comparables entre las dos bases** — PSI de 2.74, rejillas de valores casi disjuntas. El modelo se apoya por eso en el *ratio saldo/capital*, invariante a la escala del monto, y no en el monto absoluto.

La validación se hizo sobre **tres bloques disjuntos** (entrenamiento 60 %, calibración 20 %, prueba 20 %) agrupados por vector de atributos, de modo que filas idénticas nunca queden a la vez en entrenamiento y prueba; la semilla es fija y el bloque de prueba no se tocó hasta producir las cifras de este informe. La evidencia numérica de las tres condiciones anteriores y el detalle del esquema están en §2.

Dónde está el dinero, y dónde está el riesgo

No son el mismo lugar, y conviene decirlo con claridad: los clientes con mayor probabilidad de fuga son los de *menor* saldo, porque el saldo bajo es justamente la señal de que el crédito está por terminar. El segmento de riesgo alto representa \$2.6 millones de saldo vigente sobre un total de \$57.2 millones. Por eso la campaña no se prioriza por saldo actual sino por el **margen del ciclo de crédito que se perdería** si el cliente no renueva (§4.3).

2 Datos, auditoría y validación

Esta sección aporta la evidencia de lo que el resumen enuncia. Es el núcleo metodológico del trabajo: sin las dos correcciones que aquí se documentan, las métricas del modelo serían impecables y sus predicciones, inservibles.

2.1 Las tres bases

Base de Datos Modelo

78 829 registros, 14 columnas, una fila por cliente: los códigos de cliente son únicos y el código de préstamo es exactamente diez veces el código de cliente. No es un panel cliente–mes, pese a que el enunciado menciona 30 meses de comportamiento.

Base de Datos Predicción

10 000 clientes activos, las mismas 13 variables explicativas más las dos columnas a completar (*Probabilidad Fuga y Predicción*).

Bakery

9 981 tickets $\times$ 50 productos, ya en formato de matriz transaccional binaria.

Unidad monetaria. Las bases no declaran la unidad de los importes. Tratándose de una empresa colombiana, todas las cifras de dinero de este informe se expresan en **pesos colombianos (COP)** y se presentan en la escala original del archivo, sin conversión. Los supuestos económicos de la campaña (§4.3) se fijaron en esa misma escala, de modo que la decisión de a quién contactar no depende de la unidad elegida.

2.2 Auditoría de variables

Una variable tiene fuga de información cuando sólo pudo conocerse *después* o *a causa* de que el cliente se fuera; usarla produce un modelo que parece excelente y no sirve. El diagnóstico se hizo calculando el AUC univariado de cada variable contra el objetivo, y dos resultados obligaron a intervenir: el identificador de cliente y el indicador de primer crédito, ya enunciados en el resumen. **Su evidencia numérica completa está en el anexo A**, junto con la deriva de montos entre bases

y la verificación de que el saldo sí es comparable. La tabla siguiente recoge la decisión adoptada sobre cada variable.

Tabla 1: Decisión adoptada sobre cada variable y su justificación.

Variable	Decisión	Justificación
CODIGO CLIENTE	Descartada	AUC univariado = 1.000. El archivo fue ordenado por ESTADO antes de numerarse: retirados 1–34 354, renovados 34 355–88 828. En la base de predicción se renumeró 1–10 000.
CODIGO PRESTAMO	Descartada	Es exactamente diez veces el código de cliente en el histórico. Hereda la misma fuga.
CREDITOS ANTERIO-RES	Tratada aparte	El valor 1 implica el objetivo por definición (12 791 de 12 791 retirados): renovar exige un segundo crédito. Se modela como segmento separado.
SALDO_CAPITAL	Conservada	Comparable entre bases: la distribución de los activos se sitúa entre la de renovados y retirados (KS = 0.144 contra el histórico completo).
CAPITAL_CONCEDIDO	Conservada con cautela	Deriva severa entre bases (PSI = 2.74; rejillas de valores casi disjuntas). Se prioriza el ratio saldo/capital, invariante a escala.
ETAPA	Conservada	Escalón de deterioro observable al momento de decidir. M3 concentra 98.2 % de fuga en el histórico.
TIPO DE CREDITO	Conservada y limpiada	12 niveles aparentes se reducen a 8 tras normalizar espacios y mayúsculas.
SEXO	Conservada y limpiada	Un registro con valor vacío se recodifica como 'ND'. AUC univariado 0.502: sin poder predictivo.

Se corrigieron además dos defectos de calidad: TIPO DE CREDITO presentaba 12 niveles aparentes que se reducen a 8 tras normalizar espacios en blanco y mayúsculas (los valores 'C' y 'C ' figuraban como categorías distintas), y un registro tenía el sexo en blanco.

2.3 Esquema de validación

Tres bloques disjuntos

Entrenamiento 60 %, calibración 20 %, prueba 20 %. El bloque de calibración es independiente del de entrenamiento, y el de prueba no se tocó hasta producir las cifras finales de este informe.

Agrupación por vector de atributos

7 803 filas tienen atributos idénticos a otra fila. Con particiones aleatorias simples caerían a la vez en entrenamiento y prueba e inflarían artificialmente las métricas; las particiones se construyeron agrupando por el vector de atributos.

Validación cruzada

Cinco particiones estratificadas y agrupadas, para comparar la escalera de modelos con predicciones fuera de partición.

Reproducibilidad

Semilla fija (42) en todos los procesos.

Como no hay fechas, no es posible una validación fuera de tiempo, que sería el esquema correcto

para replicar las condiciones de aplicación; el diseño anterior es su sustituto. Se deja constancia, además, de que 587 grupos de atributos idénticos presentan ambos desenlaces: ese es el ruido irreducible del problema y fija un techo al desempeño alcanzable con las variables disponibles.

3 Modelo de predicción de fuga

3.1 Algoritmos evaluados

► Responde al inciso 1.a

Se evaluó una escalera completa de modelos, de menor a mayor complejidad, y se reporta entera: presentar únicamente el ganador oculta si la complejidad adicional estaba justificada.

Tabla 2: Escalera de modelos. Métricas fuera de partición sobre el bloque de entrenamiento, salvo la regla de negocio.

Modelo	AUC-PR	AUC-ROC	KS	Lift decil 1	Captura al 20 %
Regla de negocio (ratio<0.15 ó ETAPA>=M2)	0.520	0.807	0.614	1.93	41.5 %
Regresión logística	0.774	0.918	0.699	3.19	58.8 %
Random Forest	0.817	0.931	0.714	3.40	61.7 %
LightGBM	0.848	0.944	0.749	3.52	63.5 %
Ensamble (promedio de rangos)	0.837	0.939	0.733	3.47	63.0 %
LightGBM SIN variables de saldo (robustez)	0.696	0.850	0.510	3.20	51.3 %

Nivel 0 — Regla de negocio

“Está en riesgo si ya amortizó más del 85 % de su crédito o si está en etapa M2/M3”. Es la línea base que la gerencia ya entiende, y sirve para medir cuánto aporta realmente el modelo.

Nivel 1 — Regresión logística

Referencia obligada en riesgo crediticio por su interpretabilidad. Con codificación *one-hot* y estandarización dentro de un *pipeline* ajustado sólo con datos de entrenamiento.

Nivel 2 — Random Forest

Referencia no lineal.

Nivel 3 — LightGBM

Modelo seleccionado. Maneja las categóricas de alta cardinalidad de forma nativa (138 agencias, 40 subproductos) sin expandir la matriz.

Nivel 4 — Ensamble

Promedio de rangos de los tres anteriores. No mejoró al LightGBM en solitario, de modo que se descartó: no se añade complejidad que no paga.

Se incluye además una **prueba de robustez** (fila 3b): el mismo LightGBM entrenado sin ninguna variable derivada del saldo alcanza AUC-ROC de 0.850, frente a 0.944 del modelo completo medido sobre el mismo esquema de validación cruzada. Es decir, el modelo conserva capacidad predictiva sustancial incluso si se sospechara del saldo, lo que acota el riesgo de que el resultado dependa de una sola familia de variables.

3.2 Modelo seleccionado y calibración de probabilidades

► Responde al inciso 1.b

Respuesta directa: se utilizó **LightGBM** (*gradient boosting* sobre árboles) para ordenar el riesgo, y **regresión isotónica** ajustada sobre un conjunto de calibración independiente para convertir ese ordenamiento en una probabilidad interpretable como porcentaje. La verificación se hizo con curva de confiabilidad y *Brier score*.

La distinción importa porque el inciso 1.d pide un *porcentaje* de probabilidad, no un puntaje. Un modelo puede ordenar perfectamente a los clientes y aun así entregar números que no signifiquen nada como probabilidad. Por eso se separan las dos tareas:

1. **Ordenar** — LightGBM, elegido por desempeño en la tabla 2.
2. **Calibrar** — regresión isotónica, ajustada exclusivamente sobre el bloque de calibración, nunca sobre los datos de entrenamiento ni sobre los de prueba.

El *Brier score* sobre el conjunto de prueba pasa de 0.0877 sin calibrar a 0.0869 tras la calibración isotónica. Se probó también el método de Platt, que resultó peor (0.0917). Conviene señalar con honestidad que **la mejora por calibrar fue marginal**: el LightGBM ya salía prácticamente calibrado. Se conserva la isotónica porque el inciso pide explícitamente un porcentaje y la garantía adicional no tiene costo relevante.

Sobre el desbalance

No se aplicó SMOTE ni submuestreo. Con 38 % de prevalencia el desbalance es moderado, y ambas técnicas **destruyen la calibración de las probabilidades**, que es precisamente lo que el inciso 1.d requiere. Se usó ponderación de clases donde correspondía, y se evitó la métrica de exactitud (*accuracy*) en todo el ejercicio.

3.3 Desempeño

Tabla 3: Probabilidad predicha frente a tasa real observada, por decil de riesgo, sobre el 20 % de datos reservados. Es la evidencia central de que la probabilidad entregada es utilizable como porcentaje.

Decil	Clientes	Probabilidad predicha	Tasa real observada	Lift	Captura acum.
1	1 321	93.3 %	92.2 %	3.51	35.2 %
2	1 320	75.3 %	70.8 %	2.70	62.1 %
3	1 320	52.5 %	53.3 %	2.03	82.4 %
4	1 320	28.5 %	30.2 %	1.15	93.9 %
5	1 320	8.4 %	12.1 %	0.46	98.6 %
6	1 320	2.8 %	2.6 %	0.10	99.5 %
7	1 320	1.0 %	0.8 %	0.03	99.8 %
8	1 320	0.1 %	0.2 %	0.01	99.9 %
9	1 320	0.0 %	0.3 %	0.01	100.0 %
10	1 320	0.0 %	0.0 %	0.00	100.0 %

Las dos columnas centrales coinciden decil a decil. Cuando el modelo dice 93 %, se retiran 92 de cada 100; cuando dice 28 %, se retiran 30 de cada 100. Las métricas globales sobre el mismo conjunto son: AUC-ROC 0.940, AUC-PR 0.835 y KS 0.737.




Figura 1: Curva de ganancia acumulada sobre la cartera activa. Contactando al 20 % de mayor riesgo se cubre el 62 % de las fugas esperadas.

3.4 Variables de mayor impacto

► Responde al inciso 1.c

La importancia se midió con **SHAP** y no con la importancia por ganancia de los árboles, que está sesgada hacia variables de alta cardinalidad y no indica el sentido del efecto.

Tabla 4: Variables ordenadas por su peso relativo en la decisión del modelo.

Variable	Peso relativo	Sentido del efecto
Saldo pendiente / capital concedido	31.0 %	Reduce la fuga
Interacción saldo/capital x nº créditos	10.4 %	Reduce la fuga
Subproducto	9.8 %	Categorica
Tasa vs. promedio de su producto	9.5 %	Reduce la fuga
Agencia	7.0 %	Categorica
Etapas de deterioro (M1/M2/M3)	5.9 %	Categorica
Producto	5.1 %	Categorica
Saldo de capital vigente (Q)	4.1 %	Reduce la fuga
Tipo de crédito	2.8 %	Categorica
Número de créditos del cliente	2.6 %	Reduce la fuga




Figura 2: Peso relativo de cada variable.

Traducción al lenguaje del negocio

1. Qué tan avanzado va el cliente en el pago de su crédito (31 % del peso)

Es, con diferencia, la señal dominante. Un cliente que ya amortizó más del 90 % de su crédito y no ha vuelto a solicitar está en la puerta de salida: en ese tramo la tasa de fuga histórica es del 81 %. Un cliente con un desembolso reciente y más del 60 % del capital pendiente prácticamente no se va: su tasa es del 1 % al 5 %. **La fuga en microcrédito no ocurre en cualquier momento: ocurre en la ventana de renovación.**

2. La interacción entre el avance del crédito y la antigüedad (10 %)

El mismo nivel de amortización significa cosas distintas según la trayectoria del cliente. Un cliente en su segundo crédito con el 90 % pagado se retira en el 81 % de los casos; uno en su noveno crédito, en el 12 %. **La lealtad acumulada amortigua el riesgo de la ventana de renovación.**

3. Subproducto y tasa relativa a su producto (19 % combinado)

La tasa que se le cobra al cliente *comparada con la de sus pares del mismo producto* pesa más que la tasa en términos absolutos. Es un hallazgo accionable: sugiere sensibilidad al precio relativo, no al precio.

4. Agencia (7 %)

Hay diferencias sistemáticas de retención entre agencias que las variables del cliente no explican. Apunta a prácticas comerciales locales y merece revisión operativa.

5. Etapas de deterioro (6 %)

Los clientes en M3 se retiran en el 98 % de los casos. Es una señal potente, pero llega tarde: cuando aparece, la retención comercial ya no es el instrumento adecuado.

Contraste y estabilidad

El coeficiente del ratio saldo/capital en la regresión logística es -3.10 (razón de momios 0.045), el segundo de mayor magnitud del modelo lineal. Los dos enfoques, uno lineal y otro basado en árboles, coinciden en señalar la misma variable como dominante y en la misma dirección, lo que refuerza la lectura.

El ranking se recalculó en cinco particiones independientes: las ocho primeras variables mantienen su posición con desviación estándar de 0 a 1 puesto. La jerarquía no es un artefacto de una partición concreta.

4 Aplicación a los clientes activos

4.1 Tratamiento del segmento de primer crédito

Antes de presentar las probabilidades hay que resolver el problema planteado en §2.2: en el histórico, el primer crédito determina el objetivo por definición, de modo que ese subconjunto no aporta información discriminante. El modelo principal se entrenó, por tanto, sobre los 66 038 clientes con dos o más créditos, donde la tasa de fuga es 26.1 %.

Para los 1 873 activos en su primer crédito se separó el problema en dos:

El ordenamiento

se toma del modelo entrenado con los demás clientes. Dentro del segmento, quien lleva más amortizado y menos saldo sigue siendo el más propenso a irse.

El nivel

se estima extrapolando la curva empírica de fuga frente al número de créditos. Ajustando una relación logit-lineal sobre los tramos de 2 a 5 créditos — donde la extrapolación a 1 es creíble — se obtiene una tasa estimada de **49.6 %** para el primer crédito. Se aplica como corrección de prior en escala logit, que es una transformación monótona y por tanto no altera el ordenamiento. La cifra es coherente con lo que se observa en microfinanzas: el primer ciclo es el de mayor deserción. Y es sustancialmente distinta del 100 % que arrojaría copiar la tautología del histórico. Se hizo análisis de sensibilidad sobre este supuesto: variar la tasa entre 30 % y 85 % mueve el número de clientes de primer crédito entre los 1 000 de mayor riesgo de 213 a 726, sin alterar la composición del resto de la lista.

4.2 Distribución de probabilidades de fuga

► Responde al inciso 1.d

El archivo *Genesis_Churn_Prediccion_Julio_Vicente.xlsx* contiene la base original de 10 000 clientes con las columnas *Probabilidad Fuga* (0 a 1, cuatro decimales), *prob_fuga_pct* (porcentaje), decil de riesgo, segmento de riesgo, segmento de clustering y recomendación de campaña.




Figura 3: Distribución de la probabilidad de fuga. La cartera se separa en dos poblaciones nítidas; hay poca zona intermedia.

Tabla 5: Deciles de riesgo sobre los 10 000 clientes activos.

Decil	Clientes	Prob. media	Fugas esperadas	Saldo	Captura acum.
1	1 000	94.2 %	942	\$888 109	27.4 %
2	1 000	79.2 %	792	\$731 752	50.4 %
3	1 000	66.7 %	667	\$641 140	69.8 %
4	1 000	51.1 %	511	\$674 022	84.6 %
5	1 000	35.0 %	350	\$861 263	94.8 %
6	1 000	15.1 %	151	\$1 804 829	99.2 %
7	1 000	2.3 %	23	\$6 243 874	99.8 %
8	1 000	0.3 %	3	\$5 986 365	99.9 %
9	1 000	0.2 %	2	\$17 340 437	100.0 %
10	1 000	0.0 %	0	\$22 075 673	100.0 %

Obsérvese la tensión entre las dos últimas columnas: el decil 10, el de menor riesgo, concentra el mayor saldo vigente. No es una anomalía, es la mecánica del negocio: saldo alto significa desembolso reciente, y un cliente recién desembolsado no se va. Priorizar la campaña por saldo en riesgo llevaría exactamente a los clientes equivocados.

4.3 Selección de clientes para campaña de retención

► Responde al inciso 1.e

La pregunta correcta no es “¿a quién le corresponde una probabilidad mayor a 0.5?” sino “¿a quién conviene contactar?”. Un umbral de 0.5 no tiene ninguna justificación de negocio. El criterio adoptado es el **valor esperado**:

$$\text{Beneficio esperado}(i) = P(\text{fuga}_i) \times \text{efectividad} \times \text{valor del cliente}_i - \text{costo de contacto}$$

Se recomienda contactar si el beneficio esperado es positivo.

Con dos supuestos declarados y parametrizables:

Valor del cliente

Margen financiero neto del siguiente ciclo de crédito, aproximado como $\text{capital concedido} \times \text{tasa nominal} \times 30\%$ de margen neto (después de costo de fondos, provisiones y gasto operativo). Mediana de \$832 por cliente.

Costo de contacto

\$25 por cliente: llamada más tiempo de asesor.

Efectividad de campaña

Desconocida. Se presenta análisis de sensibilidad con tres escenarios.

Tabla 6: Sensibilidad de la selección a la efectividad supuesta de la campaña.

Efectividad	Clientes	% de fugas	Retenciones	Costo	Beneficio	Retorno
10 %	3 791	77 %	264	\$94 775	\$167 952	1.8×
20 %	4 957	91 %	627	\$123 925	\$445 218	3.6×
30 %	5 374	95 %	981	\$134 350	\$732 269	5.5×

En el escenario base (20 % de efectividad) se recomienda contactar a 4 957 clientes, que concentran el 91 % de las fugas esperadas, con un costo de \$123 925 y un beneficio esperado de \$445 218.

Versión con restricción de capacidad

Contactar a la mitad de la cartera puede exceder la capacidad del área comercial. La columna *prioridad_campana* del archivo entregado ordena a los 10 000 clientes por valor esperado descendente, de modo que la operación puede cortar donde su capacidad se lo permita:

Tabla 7: Resultado esperado según la capacidad de contacto disponible.

Capacidad	Prob. media	Fugas en lista	% del total	Retenciones	Beneficio
500	78 %	388	11 %	78	\$199 984
1 000	83 %	826	24 %	165	\$261 123
1 500	82 %	1 228	36 %	246	\$308 573
2 000	80 %	1 601	46 %	320	\$347 075
3 000	75 %	2 251	65 %	450	\$403 996

Traducción operativa: si el área comercial puede atender 1 000 contactos al mes, esos 1 000 clientes concentran 826 fugas esperadas — el 24 % del total — con un costo de \$25 000 y un beneficio esperado de \$261 123.

Una advertencia honesta

Un modelo de fuga identifica *quién se va a ir*, no a *quién la campaña va a convencer*. No son el mismo grupo: hay clientes de altísimo riesgo que se irán de todas formas, y clientes que habrían renovado sin necesidad de contacto. Optimizar el segundo problema requiere **modelado de incrementalidad** (*uplift*), que a su vez exige una campaña ejecutada con grupo de control aleatorizado.

Recomendación para el siguiente ciclo

Ejecutar la primera campaña dejando un **10 % de grupo de control aleatorio** sin contactar. Eso permite medir la efectividad real — que hoy es un supuesto — y entrenar un modelo de incrementalidad en el siguiente ciclo, que priorizaría a los clientes *persuadibles* y no simplemente a los riesgosos.

5 Segmentación de clientes

► Responde al inciso 1.f

5.1 Metodología y selección de k

Las variables se eligieron con intención, siguiendo un marco RFM adaptado a cartera de crédito, en lugar de introducir el catálogo completo: monto (logaritmo del capital concedido), frecuencia (número de créditos), posición en el ciclo de vida del crédito (ratio saldo/capital), precio (tasa nominal) y deterioro (etapa).

Sólo variables numéricas

Aplicar k -medias sobre categóricas de alta cardinalidad codificadas en *one-hot* (138 agencias) produce distancias sin significado. Las categóricas se reservaron para *perfilar* los segmentos ya formados.

Winsorización en los percentiles 1 y 99

Sin ella, k -medias dedicaba segmentos enteros a un puñado de casos extremos (hasta 106 créditos), generando grupos de 54 y 83 clientes, inservibles para el área comercial.

Escalado robusto

Por la presencia de valores atípicos en los montos.

Elección de k con tres criterios y una prueba de estabilidad

Se evaluó k de 2 a 8 con coeficiente de silueta, índice de Davies–Bouldin y codo de inercia, y se añadió una prueba que rara vez se hace: **estabilidad por remuestreo**. Se reagruparon 10 muestras *bootstrap* y se midió el índice de Rand ajustado (ARI) entre particiones.

k	Silueta	Davies–Bouldin	ARI medio	Desv. ARI
4	0.231	1.534	0.810	0.257
5	0.244	1.292	0.794	0.226
6	0.262	1.187	0.971	0.012
7	0.256	1.168	0.895	0.147

Tabla 8: Diagnóstico de selección de k . Se eligió $k = 6$.

$k = 6$ **domina a sus alternativas en los tres criterios a la vez**: mejor silueta, menor Davies–Bouldin y una estabilidad muy superior (ARI de 0.971 con desviación de 0.012, frente a 0.794 con desviación de 0.226 para $k = 5$). Un agrupamiento que no es estable no es accionable; éste lo es. Y seis segmentos siguen siendo un número manejable para un área comercial.

El modelo se ajustó sobre los 78 829 clientes históricos y se aplicó a los 10 000 activos, lo que permite comparar la tasa de fuga observada de cada segmento con la probabilidad media que el modelo asigna a sus clientes activos.

5.2 Perfil de cada segmento

Tabla 9: Los seis segmentos, ordenados por tasa de fuga histórica observada.

Segmento	Hist.	% clientes	% cartera	Fuga obs.	Prob. activos	Activos
Primer crédito en deterioro	4 985	6.3 %	2.1 %	97.7 %	87.7 %	434
Microcrédito pequeño por vender	22 970	29.1 %	5.2 %	61.8 %	49.3 %	3 257
Crédito mediano próximo a cancelar	12 013	15.2 %	10.5 %	41.5 %	39.5 %	1 294
Recurrente de monto bajo	18 278	23.2 %	6.5 %	29.9 %	40.7 %	2 262
Crédito vigente en ciclo temprano	11 375	14.4 %	28.3 %	3.4 %	0.9 %	1 336
Cliente consolidado de alto monto	9 208	11.7 %	47.3 %	1.3 %	0.9 %	1 417

Tabla 10: Rasgos que definen cada segmento (medianas).

Segmento	Capital	Saldo	% pagado	Créditos	En mora	Mujeres
Primer crédito en deterioro	\$5 000	\$831	85 %	1	100.0 %	63 %
Microcrédito pequeño por vender	\$3 000	\$560	86 %	2	2.9 %	71 %
Crédito mediano próximo a cancelar	\$12 000	\$1 422	89 %	4	4.0 %	63 %
Recurrente de monto bajo	\$5 000	\$885	82 %	4	4.2 %	83 %
Crédito vigente en ciclo temprano	\$8 000	\$5 765	35 %	3	9.1 %	60 %
Cliente consolidado de alto monto	\$20 000	\$12 660	38 %	6	4.1 %	63 %




Figura 4: Tasa de fuga histórica observada frente a probabilidad media asignada a los clientes activos del mismo segmento. La correspondencia entre ambas es una validación cruzada entre los dos ejercicios: el modelo de fuga y el de segmentación, contruidos por separado, coinciden.

Fichas de segmento

Primer crédito en deterioro — 6.3 % de clientes, 2.1 % de cartera, fuga 97.7 %

El 100 % está en etapa M2 o M3 y el 73 % cursa su primer crédito. Capital mediano de \$5 000. *Acción:* esto no es un problema comercial sino de cobranza y reestructuración. Gastar presupuesto de retención aquí es gastarlo mal; lo que corresponde es gestión de recuperación.

Microcrédito pequeño por vencer — 29.1 % de clientes, 5.2 % de cartera, fuga 61.8 %

El segmento más numeroso y el que más fugas aporta en volumen. Capital mediano de \$3 000, tasa alta (43.6), 86 % del crédito ya pagado, dos créditos de trayectoria, 71 % mujeres. *Acción:* oferta de renovación anticipada con monto escalonado, disparada automáticamente al alcanzar el 80 % de amortización. Es el segmento donde la intervención temprana rinde más.

Crédito mediano próximo a cancelar — 15.2 % de clientes, 10.5 % de cartera, fuga 41.5 %

Capital mediano de \$12 000, cuatro créditos de trayectoria, tasa baja (30), 89 % amortizado. Son clientes buenos y recurrentes justo en el punto de decisión. *Acción:* renovación proactiva con incremento de monto. Es cartera de valor que se está dejando ir.

Recurrente de monto bajo — 23.2 % de clientes, 6.5 % de cartera, fuga 29.9 %

Cuatro créditos, capital mediano de \$5 000, 83 % mujeres — la mayor concentración femenina de la cartera. *Acción:* fidelización con beneficio por antigüedad y mejora de tasa.

Crédito vigente en ciclo temprano — 14.4 % de clientes, 28.3 % de cartera, fuga 3.4 %

Desembolso reciente, 64 % del capital pendiente. *Acción:* ninguna. Contactarlos consumiría presupuesto sin efecto: no se están yendo.

Cliente consolidado de alto monto — 11.7 % de clientes, 47.3 % de cartera, fuga 1.3 %

Capital mediano de \$20 000, seis créditos, tasa preferencial. Concentran casi la mitad de la cartera con la menor tasa de fuga. *Acción:* gestión personalizada por ejecutivo de cuenta. El riesgo aquí no es la fuga silenciosa sino la pérdida de un cliente de alto valor por desatención.

5.3 Cruce entre segmento y riesgo de fuga

Tabla 11: Clientes activos por segmento y nivel de riesgo, con el saldo expuesto en riesgo alto. Es la matriz que convierte dos ejercicios separados en una sola priorización.

Segmento	Riesgo alto	Riesgo medio	Riesgo bajo	Saldo en riesgo alto
Microcrédito pequeño por vencer	1 564	1 074	619	\$893 604
Crédito vigente en ciclo temprano	6	9	1 321	\$97 953
Crédito mediano próximo a cancelar	520	231	543	\$528 053
Primer crédito en deterioro	402	21	11	\$512 104
Recurrente de monto bajo	991	471	800	\$538 582
Cliente consolidado de alto monto	2	9	1 406	\$17 695

5.4 Patrones encontrados

1. **La fuga es un fenómeno de ventana, no de perfil.** El factor que más separa a quien se va de quien se queda no es su monto, su región ni su sexo: es en qué punto del ciclo de su crédito se encuentra. Los tres segmentos de mayor fuga son precisamente los que tienen el crédito casi liquidado.
2. **La antigüedad protege, y protege mucho.** La tasa de fuga cae de 34.5 % en el segundo crédito a 4.3 % en el octavo. Cada renovación lograda reduce de forma marcada la probabilidad de la siguiente deserción: retener hoy tiene retorno compuesto.
3. **El valor y el riesgo están en extremos opuestos de la cartera.** El 47 % del saldo está en el segmento con 1.3 % de fuga; los segmentos con fuga superior al 60 % suman apenas el 7 % de la cartera. Gestionar por saldo en riesgo llevaría a ignorar a casi todos los clientes que efectivamente se van.
4. **El monto pequeño y la tasa alta van juntos, y ambos con la fuga.** Los segmentos de menor capital pagan tasas de 43.6 frente al 30 de los segmentos consolidados. Es la estructura habitual del microcrédito, pero señala una palanca concreta: la tasa relativa a los pares del mismo producto figura entre las cinco variables más predictivas.
5. **Hay un efecto de agencia que las variables del cliente no explican.** La agencia aporta el 7 % del peso del modelo. Dos clientes idénticos atendidos en agencias distintas tienen probabilidades de retención apreciablemente diferentes, lo que apunta a prácticas comerciales locales replicables.

6 Reglas de asociación — base Bakery

6.1 Reglas encontradas

► Responde al inciso 2.a

La base contiene 9 981 tickets y 50 productos, con un promedio de 3.56 artículos por ticket. Se usó **FP-Growth** (más eficiente que Apriori) con soporte mínimo de 1 %, umbral bajo y apropiado para tickets cortos. Se obtuvieron 124 conjuntos frecuentes y 352 reglas con lift superior a 1.

Tabla 12: Las 14 canastas seleccionadas, ordenadas por lift.

Canasta	Tickets	Soporte	Confianza	Lift
Green Tea + Lemon Cookie + Lemon Lemonade + Raspberry Cookie + Raspberry Lemonade	196	2.0 %	98 %	36.4×
Apple Croissant + Apple Danish + Apple Tart + Cherry Soda	204	2.0 %	94 %	34.2×
Almond Twist + Apple Pie + Coffee Eclair + Hot Coffee	266	2.7 %	75 %	24.8×
Chocolate Tart + Vanilla Frappuccino + Walnut Cookie	284	2.8 %	38 %	12.5×
Casino Cake + Chocolate Cake + Chocolate Coffee	323	3.2 %	94 %	11.7×
Blackberry Tart + Coffee Eclair + Single Espresso	266	2.7 %	92 %	11.6×
Apricot Croissant + Blueberry Tart + Hot Coffee	348	3.5 %	92 %	11.1×
Apricot Danish + Cherry Tart + Opera Cake	405	4.1 %	95 %	10.5×
Berry Tart + Bottled Water	366	3.7 %	51 %	6.0×
Marzipan Cookie + Tuile Cookie	484	4.8 %	50 %	6.0×
Napoleon Cake + Strawberry Cake	457	4.6 %	50 %	5.9×
Cheese Croissant + Orange Juice	437	4.4 %	54 %	5.8×
Gongolais Cookie + Truffle Cake	441	4.4 %	51 %	5.5×
Lemon Cake + Lemon Tart	362	3.6 %	42 %	5.3×

Canastas de compra: 12 grupos de productos que se venden juntos
cada grupo es una canasta · el grosor del enlace es el lift · el tamaño del círculo es la frecuencia del producto




Figura 5: Red de co-ocurrencia entre productos. Los conglomerados corresponden a las canastas identificadas.

6.2 Criterio de selección de las reglas

► Responde al inciso 2.b

Se aplicaron cuatro filtros simultáneos y un paso de depuración:

1. **Lift** > 1.20 — que la asociación sea real y no un efecto de la popularidad de los productos.
2. **Al menos 100 tickets de respaldo** — que el hallazgo tenga sustento muestral y no sea una coincidencia de una veintena de compras.
3. **Confianza superior a 1.2 veces el soporte del consecuente** — que la regla mejore de forma apreciable sobre la línea base de comprar ese producto sin más.
4. **Leverage positivo** — co-ocurrencia por encima de lo esperado bajo independencia.

La patología de esta base no es la habitual

El error clásico en una panadería es presentar reglas con confianza altísima y lift cercano a 1: “quien compra X también compra pan” es cierto de todo el mundo y no informa nada. **Aquí ese problema casi no existe:** el producto más vendido, Coffee Eclair, aparece apenas en el 10.9 % de los tickets, así que no hay ningún artículo ubicuo que genere reglas triviales. De hecho, ninguna de las 352 reglas tiene confianza superior al 20 % con lift inferior a 1.20.

La patología dominante en esta base es la redundancia. Las 352 reglas describen sólo 74 conjuntos de productos distintos, y esos 74 se reducen a 14 hallazgos comerciales independientes. El conjunto {Lemon Cookie, Raspberry Cookie, Lemon Lemonade, Raspberry Lemonade, Green Tea} genera por sí solo **180 reglas** con métricas casi idénticas — todas las formas de repartir esos cinco productos entre antecedente y consecuente — y el conjunto de los cuatro productos de manzana genera otras 50. Presentar ese recuento como 230 hallazgos sería un error de lectura: son dos.

El paso de depuración consistió, por tanto, en **colapsar cada regla a su conjunto de productos subyacente** (antecedente unido a consecuente), conservar una sola regla representante por conjunto — la de mayor lift — y eliminar los conjuntos contenidos en otro que no lo mejorara. De 352 reglas quedan 14 canastas genuinamente distintas.

6.3 Uso recomendado de los resultados

► Responde al inciso 2.c

1. **Combos empaquetados con precio propio.** Las tres canastas de mayor lift se compran juntas entre 25 y 36.4 veces más de lo que ocurriría por azar. Merecen ser productos de catálogo con precio de paquete, no una sugerencia del vendedor: el combo *Apple Croissant + Apple Danish + Apple Tart + Cherry Soda* aparece en 204 tickets con 93.6 % de confianza.
2. **Disposición física del mostrador.** Ubicar contiguos los productos de cada canasta y colocar la bebida asociada junto a su repostería. La canasta *Almond Twist + Apple Pie + Coffee Eclair + Hot Coffee* indica que la vitrina de bollería y la barra de café no deberían estar separadas.
3. **Recomendador en punto de venta y en pedido en línea.** Cuando el cliente lleva tres de los cuatro productos de una canasta, sugerir el cuarto: la confianza en ese escenario supera el 90 %, la tasa más alta de conversión que se puede esperar de una sugerencia.
4. **Producción y compras conjuntas.** Los productos de una misma canasta deben planificarse con la misma proyección de demanda. Quebrar el inventario de uno arrastra la venta de los otros tres, lo que convierte un faltante puntual en una pérdida multiplicada.
5. **Cómo medir que funcionó.** Prueba A/B por sucursal o por semana, midiendo ticket promedio y unidades por ticket contra un grupo de control. Sin grupo de control, cualquier mejora observada se confunde con estacionalidad.

Limitación declarada: la base no incluye fecha, hora, cantidad ni precio unitario. No fue posible, por tanto, analizar patrones por franja horaria — que en una panadería cambian radicalmente entre el desayuno y la tarde — ni ordenar las reglas por impacto económico. Con esos campos, la priorización debería hacerse por dinero y no por lift.

7 Tablero de visualización

► Responde al inciso 1.f (dashboard) y 3

Se construyó un tablero interactivo de cinco páginas, entregado como un único archivo HTML autónomo:

Tablero_Cartera_Riesgo_Julio_Vicente.html

Se abre con doble clic en cualquier navegador. No requiere servidor, conexión a internet ni instalación: los datos van embebidos en el propio archivo.

Página 1 — Predicción de fuga

Indicadores de cartera, curva de ganancia, distribución de probabilidades, tabla de calibración, variables de mayor impacto y escalera de modelos.

Página 2 — Segmentación

Fichas de los seis segmentos, comparación entre tasa histórica y probabilidad de los activos, cruce segmento $\times$ riesgo y desglose por región.

Página 3 — Canastas Bakery

Reglas depuradas, penetración de productos y recomendaciones de uso.

Página 4 — Simulador de campaña

Permite mover la efectividad supuesta, el costo de contacto y la capacidad del área comercial, y recalcula en el acto cuántos clientes conviene contactar, cuántas retenciones se esperan y cuál es el retorno. El cálculo se hace sobre los 10 000 clientes reales, no sobre una aproximación.

Página 5 — Metodología

Trazabilidad de las decisiones: fuga de información detectada, diseño de validación y limitaciones.

Sobre la herramienta. El enunciado admite “Power BI o cualquier otro software que facilite la visualización”. Se optó por un tablero web autónomo por dos razones. La primera es de **confidencialidad**: se trata de información de clientes de una entidad financiera, y publicarla en un servicio de alojamiento público de tableros sería inadecuado; este tablero funciona sin enviar los datos a ningún servidor externo. La segunda es de portabilidad: se abre en cualquier navegador sin licencia ni instalación. Los archivos XLSX entregados están además listos para cargarse directamente en Power BI si se prefiere reproducirlo en esa herramienta.

8 Limitaciones y siguientes pasos

Lo que este modelo no puede hacer

1. **No mide el efecto de la campaña, sólo el riesgo.** Como se explicó en §4.3, identificar a quien se va no es identificar a quien se deja convencer. Requiere modelado de incrementalidad con

grupo de control.

2. **No hay validación fuera de tiempo.** Las bases no traen fechas. El esquema de tres bloques disjuntos con agrupación por atributos es lo más cercano posible, pero no reproduce la degradación que sufre un modelo al aplicarse a un período posterior.
3. **Faltan las variables más predictivas del negocio.** Sin días de mora, historial de puntualidad, fechas de desembolso ni montos de créditos anteriores, no se pudieron construir variables de tendencia — deterioro reciente frente al propio historial del cliente, caída del monto solicitado — que en cartera de microcrédito suelen dominar. Incorporarlas es la mejora de mayor retorno disponible.
4. **La deriva entre bases es real y hay que vigilarla.** El PSI de 2.74 en capital concedido indica que las dos poblaciones no son idénticas. El diseño lo mitiga apoyándose en ratios, pero conviene recalcular el PSI en cada aplicación del modelo.
5. **El segmento de primer crédito descansa en un supuesto explícito.** La tasa de 49.6 % proviene de extrapolar la curva de fuga, no de observación directa. Es la estimación defendible con los datos disponibles, y su sensibilidad está cuantificada, pero sigue siendo un supuesto.

Plan sugerido

1. Ejecutar la primera campaña con 10 % de grupo de control aleatorio.
2. Incorporar variables de comportamiento de pago y fechas al conjunto de entrenamiento; reentrenar y comparar contra la línea base actual.
3. Monitorear mensualmente el PSI de las variables de entrada y la calibración observada por decil. Reentrenar cuando la calibración se desvíe.
4. Con los resultados de la campaña con control, entrenar un modelo de incrementalidad para el segundo ciclo.

A Evidencia de la auditoría de datos

Detalle numérico de las tres condiciones de los datos enunciadas en §2.

Las dos fugas de información

Hallazgo 1 — los identificadores contienen la respuesta (AUC = 1.000)

Todos los clientes retirados tienen código entre 1 y 34 354, y todos los renovados entre 34 355 y 88 828: rangos **disjuntos**. La regla “código $\leq$ 34 354 $\Rightarrow$ retirado” acierta en el 100.0000 % de los 78 829 registros. El código no describe al cliente, describe el orden en que se ordenó el archivo antes de numerarlo — y en la base de predicción los códigos fueron reenumerados de 1 a 10 000, donde no contienen señal alguna. Ambas columnas se descartaron.

Hallazgo 2 — el primer crédito es el objetivo escrito de otra forma

Los 12 791 clientes históricos con CREDITOS ANTERIORES igual a 1 son retirados *sin una sola excepción*. No es una tasa alta: es una identidad lógica, porque renovar exige por definición un segundo crédito. En la base de predicción hay 1 873 activos en esa situación (18.7%): su desenlace todavía no ha ocurrido y asignarles 100 % de probabilidad sería trasladar la tautología. El tratamiento se describe en §4.1.

Deriva de montos entre las dos bases

El capital concedido presenta un PSI de 2.74, muy por encima del umbral de 0.25 que indica inestabilidad, por una causa estructural: las bases usan rejillas de montos casi disjuntas. Los valores \$3 000, \$4 000 y \$15 000, que cubren el 30 % del histórico, están prácticamente ausentes entre los activos; a la inversa, \$5 000 concentra el 42.6 % de los activos y apenas el 7.6 % del histórico. La respuesta de diseño fue apoyar el modelo en el ratio saldo/capital, invariante a la escala del monto.

El saldo sí es comparable entre bases

Se verificó que la distribución del ratio saldo/capital en los activos se sitúa *entre* la de renovados y la de retirados, con distancia de Kolmogorov–Smirnov de 0.144 contra el histórico completo, frente a 0.31 y 0.39 contra cada clase por separado. Si el saldo del histórico se hubiera medido después del desenlace, los activos se parecerían a los renovados; no es el caso.

B Reproducibilidad

Todo el análisis es reproducible ejecutando en orden los guiones de la carpeta `src/`. Semilla fija (42) en particiones, modelos y remuestreos.

`00_reconocimiento.py`

Estructura, esquemas y compatibilidad entre bases.

`01_auditoria.py`

AUC univariado, deriva, calidad, duplicados.

`02_auditoria_fina.py`

Hojas adicionales, deriva de montos, forma de las relaciones.

`03_trampa_identificadores.py`

Confirmación forense de las dos fugas de información.

`04_comparabilidad.py`

Verificación de que el saldo es comparable entre bases.

`features.py`

Limpieza e ingeniería de variables compartida.

`05_modelado.py`

Escalera de modelos, validación, calibración, modelo final.

`06_shap.py`

Importancia SHAP, contraste con la logística, estabilidad.

`07_prediccion.py`

Probabilidades de los 10 000, deciles, valor esperado.

`08_clustering.py`

Segmentación, elección de k , estabilidad, perfilado.

`09_bakery.py`

Reglas de asociación y depuración.

`10_entregables.py`

Construcción de los archivos XLSX.

11-13

Datos del tablero, tablero y tablas del informe.

Hiperparámetros del modelo final

LightGBM: objetivo binario, 700 árboles, tasa de aprendizaje 0.05, 48 hojas, mínimo 60 observaciones por hoja, submuestreo 0.85, submuestreo de columnas 0.80, regularización L1 0.5 y L2 2.0, semilla 42. Categóricas tratadas de forma nativa. Calibración: regresión isotónica con recorte fuera de rango.

Entorno

Python 3.12.7; pandas 3.0.5, numpy 2.5.2, scikit-learn 1.9.0, LightGBM 4.7.0, SHAP 0.52.0, mlxtend 0.25.0. Versiones exactas en `requirements.txt`.